

基于 NHANES 数据的心代谢风险数据挖掘系统

摘要：本项目使用 NHANES 公开脱敏健康数据，构建心代谢风险数据仓库，完成数据预处理、聚合分析、Apriori 关联规则和决策树分类预测，并通过 Streamlit 系统展示结果。

数据规模：全量原始合并记录经受试者级规约与成人筛选后，形成 6,113 条成人分析记录。

医学场景：识别肥胖、高血压、糖尿病、高胆固醇、不良饮食、久坐和吸烟等因素叠加形成的代谢高风险人群。

系统模块：数据导入、预处理与数据仓库、聚合分析、关联规则、分类预测、结果导出、系统说明。

分类结果：Accuracy=0.850, Precision=0.868, Recall=0.842, F1=0.

855。

数据仓库：SQLite 文件 results/nhanes_health_warehouse.db，包含 O

DS、DWD、ADS、DM 四层表。

聚合分析：按年龄分组

age_group	participants	high_risk_rate	diabetes_rate	hypertension_rate	high_cholesterol_rate
18-29	1300.000	0.218	0.026	0.156	0.435
30-44	1547.000	0.390	0.090	0.340	0.570
45-59	1425.000	0.544	0.199	0.575	0.702
60+	1841.000	0.845	0.326	0.787	0.746

聚合分析：按 BMI 分层

bmi_group	participants	high_risk_rate	diabetes_rate	hypertension_rate	obesity_rate
Normal	1761.000	0.233	0.085	0.339	0.000
Obese	2120.000	0.849	0.256	0.628	1.000
Overweight	2110.000	0.464	0.172	0.487	0.015
Underweight	122.000	0.238	0.033	0.328	0.000

Apriori 关联规则 Top 10

antecedent	consequent	support	confidence	lift
Age=60+ + BMI=Obese	Risk=High	0.103	0.989	1.879
BMI=Obese + Diabetes=Yes	Risk=High	0.087	0.983	1.868
Antihypertensive + Rx=Yes	Hypertension=Yes	0.125	0.910	1.855
Age=60+ + Diabetes=Yes	Risk=High	0.096	0.972	1.846
Obese + Diabetes=Prediabetic	Risk=High	0.082	0.967	1.838
BMI=Obese + Hypertension=Yes	Risk=High	0.210	0.963	1.830
Diabetes=Yes + Smoking=Yes	Risk=High	0.080	0.961	1.825
Diabetes=Yes + Hypertension=Yes	Risk=High	0.123	0.959	1.822
Activity=SedentaryHigh + BMI=Obese	Risk=High	0.087	0.959	1.821
Diabetes=Yes + Diet=HighFiber	Risk=High	0.091	0.954	1.811

决策树特征重要性 Top 10

feature	importance
hba1c	0.315
bmi	0.254
age_group_60+	0.127
ever_smoker	0.101
sedentary_minutes	0.060
age	0.055
fiber_g	0.037
systolic_bp	0.024
sodium_mg	0.010
triglycerides	0.009